Textos de Apresentação

Startup XYZ — Gestão de Documentos para IA | Discurso completo, pronto para ensaio e fala na banca

Equipe: Athos, Jhonatan, Gabriel, Lucas, Rafael

Este documento traz o texto de fala completo de cada integrante, e não apenas o tópico a ser abordado. A construção segue três princípios que costumam diferenciar uma apresentação mediana de uma apresentação que fixa na memória do avaliador: abrir cada bloco com uma tensão concreta em vez de uma definição genérica, nomear a alternativa descartada antes de justificar a escolhida, e fechar com uma frase curta que resume o argumento em uma única ideia memorável. O texto não precisa ser decorado palavra por palavra, mas ensaiado o suficiente para que a fala saia natural, sem leitura de slide.

Como usar este material

Leia seu bloco em voz alta pelo menos três vezes antes da apresentação, cronometrando o tempo. As frases em *itálico laranja* são indicações de cena, ou seja, o que fazer ou apontar no slide naquele momento, e não devem ser faladas. As frases em destaque azul são os pontos de maior impacto do bloco, vale garantir que saem com convicção e sem pressa.

Bloco 1 — Abertura, Problema e Requisitos

Athos — 4 minutos

Slides 1 a 4 — Capa, Entendimento do Problema, Levantamento de Requisitos e Visão Geral da Solução.

[olhar para a banca, não para o slide, ao dizer o número]

Bom dia. Antes de mostrar qualquer diagrama, eu quero deixar um número na cabeça de vocês: cinquenta mil. É essa a quantidade de documentos que a Startup XYZ recebe, todo mês, de clientes que confiam a ela algo que não pode ser perdido nem duplicado.

Porque o problema aqui não é só guardar arquivo. É guardar o único ativo que essa empresa vai ter para treinar a próxima geração da própria inteligência artificial dela.

A Startup XYZ é uma empresa SaaS em hipercrescimento. O produto dela é um agente de IA que extrai dados de PDFs e imagens enviados pelos clientes. E aqui está a primeira decisão que já separa uma solução amadora de uma solução madura: a regra de negócio diz que nenhum arquivo pode ser deletado. Nunca. Isso muda completamente o tipo de pergunta que a gente precisa responder.

Não basta perguntar 'onde eu guardo isso'. A pergunta certa é: 'como eu guardo isso para sempre, sem quebrar o caixa da empresa, e ainda assim deixando o cliente acessar o próprio arquivo rapidamente quando ele precisar?' Essa tensão entre acesso rápido e custo baixo de longo prazo é o fio condutor de tudo que vocês vão ver hoje.

[transição de slide: Levantamento de Requisitos]

Para resolver isso com disciplina, separamos os requisitos em dois grupos. Do lado funcional: o cliente precisa enviar documento autenticado, precisa recuperar só os arquivos dele, e o sistema precisa isolar

completamente um cliente do outro. Do lado não funcional: segurança de ponta a ponta, escalabilidade automática para absorver o crescimento sem replanejamento manual, e controle rígido de custo, porque reter dado para sempre só é viável se o custo por arquivo cair com o tempo.

Guardem essa frase, porque ela resume o desafio inteiro: não construímos um repositório de arquivos. Construímos uma estratégia de valor ao longo do tempo.

[transição de slide: Visão Geral da Solução]

Em uma frase, sem jargão técnico ainda: a nossa solução é uma arquitetura que não usa nenhum servidor fixo, guarda o documento com segurança total durante o primeiro ano, que é quando o cliente mais acessa, e depois move automaticamente esse arquivo para uma camada de armazenamento extremamente barata, sem jamais apagar o dado. Agora eu passo para o Jhonatan, que vai mostrar exatamente como cada peça dessa arquitetura entrega essa promessa.

Bloco 2 — Arquitetura, Serviços e Justificativa

Jhonatan 3 minutos

Slides 5 a 8 — Diagrama de Arquitetura, Explicação dos Serviços, Justificativa da Escolha e Mapeamento de Requisitos.

[apontar o diagrama da esquerda para a direita conforme fala cada seta]

Obrigado, Athos. Eu vou fazer uma provocação antes de mostrar o diagrama: a forma mais simples de resolver isso seria colocar um servidor rodando o tempo todo, esperando os uploads chegarem. E é exatamente isso que a gente decidiu não fazer.

Se a demanda varia, e cinquenta mil arquivos por mês raramente chegam em um fluxo constante, pagar por um servidor ligado vinte e quatro horas é pagar por ociosidade a maior parte do tempo.

Por isso a arquitetura inteira é serverless. O fluxo é direto: o cliente entra pelo Amazon API Gateway, que autentica a identidade dele e já bloqueia qualquer tentativa de abuso antes mesmo de gastar processamento. Em seguida, uma função AWS Lambda entra em ação, mas atenção a este ponto, porque é aqui que a maioria das soluções genéricas erra: essa Lambda não recebe o arquivo. Ela recebe só a identidade do usuário, confere se ele pode acessar aquele prefixo, e devolve uma URL pré-assinada com validade de quinze minutos.

O upload do arquivo em si vai direto do cliente para o Amazon S3. A Lambda nunca toca no binário. Isso significa execução em milissegundos, custo praticamente irrelevante, e nenhum limite de tamanho de arquivo imposto pela camada de API.

[apontar para o bucket S3 no centro do diagrama]

E o S3 é o coração de tudo. Escolhemos ele em vez de um sistema de arquivos tipo EFS porque os documentos aqui são imutáveis, upload único, sem edição depois. Não faz sentido pagar mais por um sistema de arquivos compartilhado quando o que a gente precisa é durabilidade. E o S3 entrega onze noves de durabilidade, replicado em múltiplas zonas automaticamente, sem uma linha de configuração extra da nossa parte.

Um detalhe que costuma gerar pergunta: por que prefixo de usuário dentro de um bucket só, e não um bucket para cada cliente? Porque a AWS limita o número de buckets por conta, e um SaaS multi-tenant com milhares de clientes explodiria esse limite rapidinho. Com prefixo mais uma política de IAM condicionada a esse prefixo, a gente consegue o mesmo isolamento, sem multiplicar a complexidade operacional.

Cada requisito que o Athos apresentou tem um componente concreto respondendo por ele. Não tem requisito órfão nessa arquitetura, e essa rastreabilidade está documentada linha por linha no nosso mapeamento de requisitos.

Agora passo a palavra para o Gabriel, que vai mostrar como essa arquitetura se comporta quando as coisas dão errado, e como ela protege o dinheiro e os dados da empresa ao mesmo tempo.

Bloco 3 — Segurança, Escalabilidade, Custos e Recuperação

Gabriel — 3 minutos

Slides 9 a 13 — Escalabilidade, Resiliência a Falhas, Segurança, Custos e Estratégia de Recuperação.

[pausa de um segundo antes de começar, tom mais firme]

Eu vou responder três perguntas que toda banca faz, e vou responder antes que vocês precisem perguntar. Primeira: o que acontece se o volume de clientes crescer dez vezes? Segunda: o que acontece se algum recurso da AWS falhar? Terceira: quanto isso custa de verdade?

Sobre crescimento: como não existe servidor fixo, não existe redimensionamento manual. O API Gateway escala sozinho, a Lambda executa uma instância isolada para cada requisição simultânea, e o S3 aceita literalmente qualquer volume de armazenamento. O único limite que existe é um limite de conta, ajustável com um pedido para a AWS, não um limite estrutural da nossa arquitetura.

Isso significa que crescer dez vezes não exige redesenhar a solução. Exige, no máximo, uma solicitação de aumento de cota.

[transição de tom: de crescimento para falha]

Sobre falhas: nenhum dos três componentes centrais, API Gateway, Lambda e S3, tem um ponto único de falha sob o nosso controle. O S3 replica cada objeto em pelo menos três zonas de disponibilidade diferentes no momento da gravação. Se uma zona inteira cair, o tráfego é redirecionado automaticamente, sem intervenção nossa e sem o cliente perceber.

E se a própria aplicação tiver um bug e tentar apagar um arquivo por engano? O Versioning do S3 está ativo. A versão anterior continua lá, recuperável em segundos. Aqui vale uma distinção técnica que gosto de deixar clara: RPO próximo de zero, porque a replicação é síncrona no momento do upload, e RTO de minutos para dado recente.

[apontar para a tabela de Lifecycle no slide]

E chegamos ao ponto que, na minha opinião, é o mais elegante da solução inteira: o custo. Nos primeiros doze meses, o documento fica em S3 Standard, acesso em milissegundos. Depois de doze meses, uma regra de Lifecycle move esse arquivo, sozinha, para o Glacier Deep Archive.

Isso reduz o custo de armazenamento em aproximadamente noventa e cinco por cento, sem apagar um único byte. E fizemos essa escolha com um motivo técnico específico: depois de um ano, o acesso deixa de ser operacional e passa a ser puramente histórico, para treinar modelos futuros de IA. Não faz sentido pagar por velocidade de acesso que ninguém vai usar.

Sobre segurança, resumo em três camadas: identidade, com IAM aplicando o princípio de menor privilégio; rede, com o bucket totalmente bloqueado para acesso público; e dado, com criptografia SSE-KMS, que permite auditar exatamente quem descriptografou o quê e quando. Passo agora para o Lucas, que vai mostrar isso funcionando de verdade, não só no papel.

Bloco 4 — Walkthrough Simulado da Arquitetura

Lucas 3 minutos

Slide 14 — Simulação Narrada do Fluxo Ponta a Ponta sobre o Diagrama.

[voltar ao slide do diagrama completo, apontador ou cursor pronto]

Até aqui vocês viram cada peça separadamente. Agora eu quero juntar tudo em uma única história: o trajeto completo de um documento real, do momento em que o cliente aperta enviar até o dia, um ano depois, em que esse arquivo já está dormindo no Glacier. Vou seguir o dedo no diagrama, passo a passo.

[apontar para o ícone do cliente, no canto esquerdo do diagrama]

Passo um: o cliente da Startup XYZ envia um PDF pelo aplicativo. Essa requisição chega autenticada no Amazon API Gateway. Reparem que, antes de qualquer processamento de negócio acontecer, o Gateway já validou identidade e já aplicou throttling. Se alguém tentasse disparar mil requisições por segundo tentando burlar isso, seria barrado exatamente aqui, nesta seta.

[mover o apontador para a seta API Gateway → Lambda]

Passo dois: a requisição chega na Lambda de autorização. Ela confere uma única coisa: esse usuário tem permissão para gravar dentro do prefixo dele mesmo? A resposta, aqui, é sim. A Lambda então gera uma URL pré-assinada, com validade de quinze minutos, e devolve essa URL para o cliente.

Reparem que, até este ponto, o arquivo em si ainda não foi transmitido nenhuma vez. Só identidade e autorização trafegaram. Isso é o que mantém essa etapa em milissegundos.

[apontar para a seta pontilhada indo direto do cliente para o bucket S3]

Passo três, e este é o pulo do gato da arquitetura: o upload do arquivo vai direto do cliente para o Amazon S3, usando aquela URL. Ele nunca passa pela Lambda de novo. O objeto é gravado dentro do prefixo do usuário, por exemplo usuario-123 barra documento.pdf, com criptografia SSE-KMS aplicada automaticamente no momento da gravação.

[apontar para o bucket S3 e para a caixa de Configurações de Segurança ao lado]

Agora eu quero que vocês simulem comigo um ataque. Imaginem que outro usuário, o usuario-456, de alguma forma descobre esse nome de arquivo e tenta acessá-lo diretamente pela URL do objeto, sem passar pela nossa Lambda.

[apontar para o ícone de cadeado em Block Public Access]

Essa tentativa morre exatamente aqui, no Block Public Access. O bucket está fechado para qualquer requisição que não venha por um caminho autorizado. Não existe link direto que funcione, porque não existe acesso público, ponto final.

E se esse mesmo usuario-456 tentasse, em vez disso, pedir para a nossa própria Lambda gerar uma URL para o arquivo do usuario-123? A política de IAM da Lambda está condicionada ao prefixo do token de quem fez a requisição. Ela simplesmente não tem permissão de assinar uma URL para um prefixo que não é o dela. O isolamento não depende de a nossa aplicação lembrar de checar isso, ele está garantido na própria permissão da AWS.

[apontar para a seta S3 → Glacier, embaixo do diagrama]

Passo quatro, agora saltando no tempo: passados os trezentos e sessenta e cinco dias, a regra de Lifecycle que configuramos identifica esse objeto e move ele, automaticamente, para o Glacier Deep Archive. Nenhuma linha de código nossa executa nesse momento, é uma regra declarativa rodando dentro do próprio S3.

Do envio até o arquivamento, o documento passou por autenticação, autorização, criptografia, isolamento por prefixo e transição de custo, e em nenhum desses cinco pontos existiu uma brecha que dependesse de alguém lembrar de fazer a coisa certa. A segurança está desenhada na arquitetura, não na disciplina de quem opera.

Passo o diagrama para o Rafael, que fecha nossa apresentação mostrando até onde essa arquitetura pode chegar.

Bloco 5 — Diferenciais e Encerramento

Rafael — 2 minutos

Slides 15 e 16 — Diferenciais, Visão de Futuro e Conclusão.

[tom mais reflexivo, ritmo um pouco mais lento que os blocos anteriores]

Tudo que vocês viram até agora resolve o problema de hoje. Mas uma equipe que só resolve o problema de hoje entrega o mínimo. Eu quero fechar mostrando que a gente já pensou no depois.

Se essa empresa crescer dez vezes, o próximo passo não é redesenhar a arquitetura, é colocar uma fila entre o upload e o processamento de IA, para nenhum pico de demanda sobrecarregar o pipeline. Se a operação amadurecer, o próximo passo é transformar toda essa infraestrutura em código, com Terraform, versionada, revisável, recriável do zero em minutos se algo catastrófico acontecer.

E se me perguntarem qual é o próximo passo em segurança, a resposta é simples: GuardDuty e Macie ligados, monitorando comportamento anômalo e dado sensível de forma automática, vinte e quatro horas por dia, sem depender de alguém olhando log manualmente.

[transição para o encerramento, olhar para todos os avaliadores]

Para fechar, eu queria voltar para o número que o Athos abriu: cinquenta mil documentos por mês, que não podem ser perdidos nunca. O problema da Startup XYZ era conciliar isso com um orçamento que não explodisse com o tempo.

A resposta que a gente construiu não é a arquitetura mais complexa que existe. É a arquitetura mais honesta com o problema: cada serviço aqui está fazendo exatamente o que ele faz de melhor, nem mais, nem menos, e o custo cai noventa e cinco por cento no momento exato em que o dado deixa de ser operação e vira patrimônio.

Segurança sólida, custo sob controle, e nenhum documento jamais perdido. Essa é a nossa arquitetura. Obrigado, e ficamos à disposição para as perguntas.

Nota final de ensaio

As frases de destaque foram escritas propositalmente curtas, para serem ditas com pausa antes e depois, sem pressa. É esse silêncio ao redor da frase que faz ela ficar na cabeça do avaliador, não o volume da voz. Ensaiem essas pausas tanto quanto ensaiam o conteúdo.